

Predicción de popularidad musical

Competencia Kaggle

Baseline

0,36930

R2 público

Modelo reproducible

0,39740

pipeline final

Mejor competencia

0,46155

ensamble calibrado

Matias Goldschmidt

Problema y datos

Objetivo

Regresión

track_popularity

Train

26.266



filas

Test

6.567

filas

El target muestra estructura:
distribución marcada y diferencias
por subgénero.



Features y preparación

Qué se construyó

Variables de audio originales: danceability, energy, valence, tempo, loudness, etc.


Variables temporales desde fecha de álbum: año, mes, década, antigüedad y fecha parcial.

Duración e interacciones: log de duración, energy x danceability, valence x energy.

Contexto musical: género, subgénero, artista, álbum, playlist y combinaciones.

Frequency encoding y target encoding out-of-fold para reducir leakage.

Lookup por track_id: 800 canciones del test ya vistas en train.



Objetivo: representar cada canción con audio, contexto, tiempo e historial, sin filtrar el target en el entrenamiento.

Features

168

predictores

Lookup

800

filas

Modelo baseline


Baseline: CatBoost inicial

CatBoost se usó como baseline porque maneja bien variables numéricas y categóricas.

Validación con GroupKFold por track_id para evitar que una canción repetida aparezca en train y validación a la vez.

El lookup aprovechó 800 canciones del test cuyo track_id ya aparecía en train.

La brecha entre OOF y Kaggle mostró que la validación interna no capturaba el cambio de dominio.



OOF R2

0,6520

validación interna

Público

0,36930

Kaggle

RMSE OOF

14,743


error interno

MAE OOF

10,665

error promedio

Por qué cayó el R2 público



Diagnóstico

El test no era una muestra ruidosa del mismo proceso: era otra población, concentrada casi completa en EDM.

Ningún split interno de train simulaba un género ausente, por eso el CV interno no alcanzaba.

A partir de ese diagnóstico, el leaderboard pasó a funcionar como señal externa de calibración.

OOF R2

0,6520

train


Público

0,36930

Kaggle

La conclusión fue cambiar la estrategia: no alcanzaba con mejorar CV; había que medir y corregir el cambio de distribución.

Selección de modelos: estrategia y pruebas



Modelos evaluados

CatBoost: modelo base principal. Se evaluaron variantes con lookup, sin lookup, sin target encoding, mayor regularización, menor learning rate y cortes top 60 / 90 / 120. El mejor modelo puro fue top 60.

ExtraTrees: no fue el mejor como modelo puro, pero aportó un ranking distinto para reordenar canciones no vistas dentro del ensamble.

LightGBM: funcionó como contraste de boosting alternativo; quedó por debajo de CatBoost en el leaderboard público.

Qué quedó de esas pruebas

CatBoost quedó como escala base de predicción.

ExtraTrees quedó como señal de ranking.

LightGBM quedó descartado como rama principal.

Luego se sumaron reglas por subgénero y calibración competitiva.

Modelo final reproducible

Ensamble CatBoost + ExtraTrees con postprocesamiento determinístico

R2 público

0,39740

Kaggle

Base predictiva

CatBoost + ET

ET 45/70/100

Ajuste final

2 reglas


subgéneros

Primero se tomó CatBoost top 60 porque fue el mejor modelo puro en el leaderboard.


Después se agregó ExtraTrees como fuente de ranking: se usó un ensemble de las variantes top 45, top 70 y top 100.

El aporte de ExtraTrees fue ordenar distinto algunas canciones no vistas, manteniendo la distribución del CatBoost.


Finalmente se aplicaron dos ajustes fijos sobre neo soul y progressive electro house, subgrupos donde el error era sistemático.



Mejor modelo de competencia



Cómo funciona la calibración competitiva



Lectura de cada prueba			
Resultado		Qué significa	Decisión
Sube el R2	→	dirección favorable	mantener o intensificar
Cae poco	→	señal con exceso	recalibrar más suave
Cae fuerte	→	dirección mala o ruido	invertir o descartar

Clave: maximiza el score público; por eso se reporta junto al modelo reproducible.

Limitaciones y posibles mejoras

Limitación, impacto y mejora posible

Drift de dominio	El test concentra EDM, dominio casi ausente en train; el CV interno no lo replica.	→	Validación por género/subgénero y datos externos de EDM.
Dependencia del LB	La mejora competitiva depende del leaderboard público y puede capturar ruido.	→	Versiones prudentes: pesos más chicos, comparación contra privado y menor sensibilidad al ruido.
Reglas manuales	Los shifts por subgénero funcionaron, pero siguen siendo reglas post-hoc.	→	Mejoras posibles: adaptación de dominio a EDM, pseudo-labeling y mayor diversidad de modelos para abrir nuevas señales.

La mejora más importante no sería sumar otro modelo, sino validar mejor el cambio de distribución.

Cierre

La historia central fue pasar de un buen modelo interno a una estrategia que reconoce el drift del test.

Punto de partida
0,36930
CatBoost baseline

Modelo reproducible
0,39740
pipeline defendible

Modelo competitivo
0,46155
mejor R2 público

La mejora reproducible vino de feature engineering, selección de modelos y postprocesamiento controlado.

Es la parte más sólida para explicar metodología y decisiones.

La mejora competitiva usó información del leaderboard público.

Sirve para maximizar performance, pero debe leerse con cautela frente al score privado.